

Informe proyecto 2

Bioseñales y sistemas. 2024

Juan Sañudo, Cristian Florez, Maria Ostos

Introducción

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel mundial, con 17,9 millones de muertes reportadas en 2019 según la Organización Mundial de la Salud (OMS). Factores como el tabaquismo, la hipertensión, el colesterol alto, la mala alimentación y el sedentarismo incrementan el riesgo de desarrollar estas enfermedades. La tecnología ha jugado un papel fundamental en la mejora del tratamiento y monitoreo de estos padecimientos, especialmente con el uso de dispositivos de bajo costo, como los electrocardiógrafos (ECG), que permiten registrar la actividad eléctrica del corazón. Sin embargo, la variabilidad de los parámetros fisiológicos requiere la recopilación de grandes volúmenes de datos para el desarrollo de modelos predictivos confiables. En este contexto, bases de datos como MIT-BIH y PhysioNet proporcionan información crítica para la validación de técnicas y modelos en distintas poblaciones, facilitando el avance de las tecnologías en el diagnóstico cardiovascular.

1)

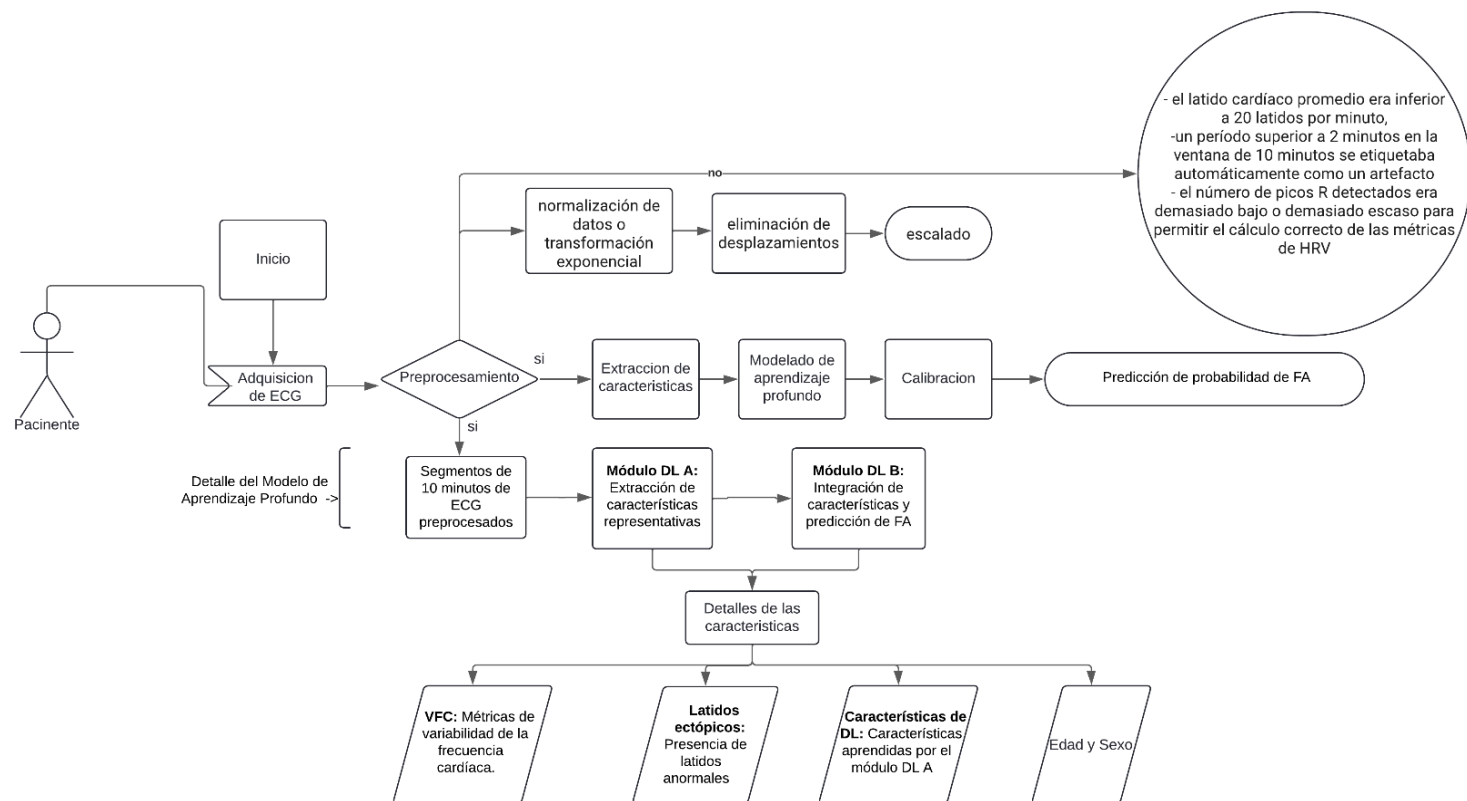
Artículo 1: Predicción de fibrilación auricular a partir de señales de ECG de una sola derivación en el hogar sin arritmias [3]

El artículo trata sobre el desarrollo de un modelo para predecir el riesgo de que una persona desarrolle fibrilación auricular (FA) o aleteo auricular en un plazo de dos semanas. Ambos trastornos se agrupan bajo el término FA por sus similitudes clínicas y tratamientos comunes. El modelo se basa en señales de ECG (electrocardiogramas) obtenidas de un parche especializado llamado iRhythm, que monitorea el ritmo cardíaco durante hasta 14 días. Las señales utilizadas no contienen episodios de FA, y el objetivo es predecir la probabilidad de que la FA ocurra en el futuro, para desarrollar este modelo, se utilizaron datos de ECG de más de 400,000 personas. El modelo se entrenó utilizando grabaciones de ECG de 10 minutos de duración y luego se ajustó para cada grupo de edad, de modo que se pudiera aplicar a una amplia gama de pacientes. Durante el entrenamiento, el modelo extrae varias características del ECG, como la variabilidad de la frecuencia cardíaca y la presencia de latidos irregulares, utilizando redes neuronales profundas.

El procesamiento del modelo se lleva a cabo en dos etapas. En la primera, se analizan segmentos cortos de ECG (10 minutos) para identificar características relevantes. En la segunda, se combinan estos análisis para evaluar el riesgo de FA en un plazo más largo. El rendimiento del modelo se evaluó en función de su precisión para predecir la FA en diferentes contextos, como tiempos de monitoreo cortos (10 minutos),

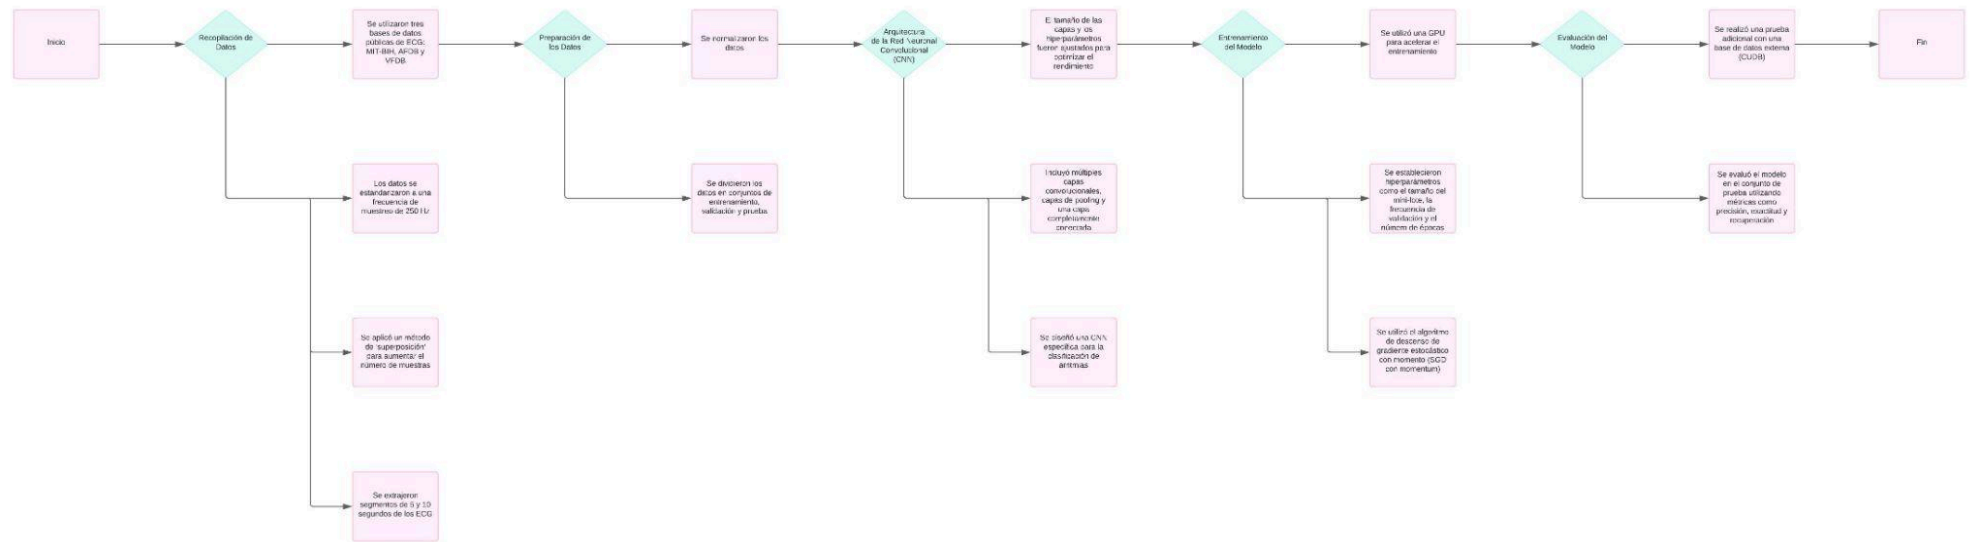
medios (1 hora) y largos (24 horas). Para garantizar resultados fiables, se implementaron técnicas de calibración y validación a lo largo de todo el desarrollo.

Este enfoque innovador busca mejorar la capacidad de predecir la FA en pacientes antes de que presenten síntomas, utilizando métodos avanzados de aprendizaje automático y análisis de datos de ECG.



Artículo 2: Enfoque óptimo de clasificación de arritmias en múltiples etapas [4]

En este artículo recopilamos datos de 40.258 electrocardiogramas (ECG) de 12 derivaciones, obtenidos de pacientes en dos hospitales entre 2013 y 2018. De los participantes, el 56% fueron hombres y el 44% mujeres, con edades predominantes entre 51 y 80 años. Los ECG se registraron durante 10 segundos a una frecuencia de muestreo de 500 Hz, y los datos fueron etiquetados por médicos, supervisados por cardiólogos. Posteriormente, agrupamos los ritmos cardíacos en cuatro categorías principales: bradicardia sinusal (SB), fibrilación auricular (FA), taquicardia supraventricular (GSVT) y ritmo sinusal (SR), siguiendo recomendaciones clínicas., para mejorar la clasificación de los ritmos cardíacos, utilizamos técnicas de procesamiento de señales para eliminar el ruido de los ECG, como el filtro de paso bajo Butterworth y la técnica robusta LOESS para la línea de base. Además, empleamos el algoritmo "Non-Local Means" (NLM) para preservar patrones repetidos y mejorar la calidad de las señales, la extracción de características fue un aspecto clave, ya que incluyó tanto variables simples como complejas relacionadas con la morfología del ECG. Calculamos 11 características básicas, además de otras derivadas de la frecuencia y morfología de los complejos QRS, picos no QRS y valles. Nuestro enfoque incluyó también un reescalado de los datos para compensar las diferencias en los ECG debidas a factores como edad y género, y una búsqueda exhaustiva de hiperparámetros para optimizar los modelos de clasificación. El objetivo de esta metodología fue maximizar la precisión en la clasificación de arritmias, un desafío dado que las señales pueden variar significativamente entre individuos.

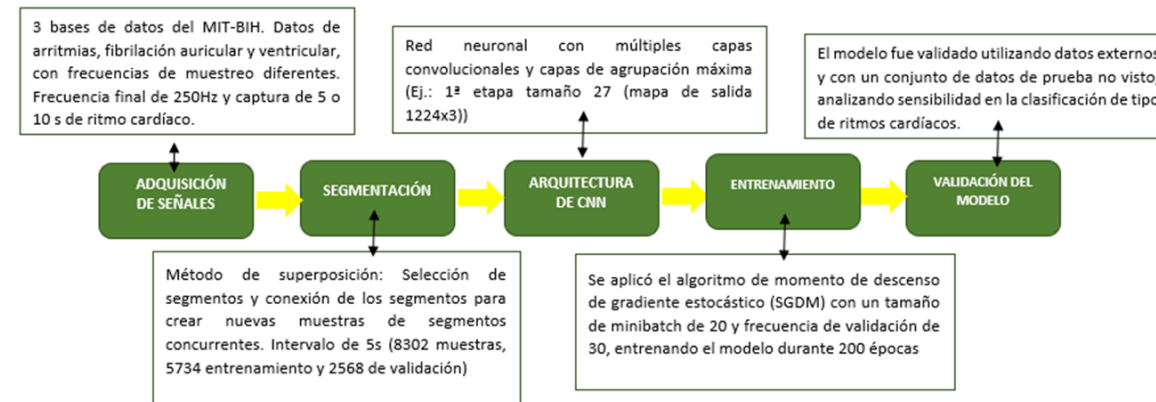


Artículo 3: Un enfoque de clasificación de arritmias mediante aprendizaje profundo utilizando ECG de una sola derivación sin detección de ondas QRS [5]

En el estudio utilizaron datos de tres bases de datos (MITDB, AFDB y VFDB) de ritmos cardíacos, extrayendo nueve tipos diferentes de ritmos. Para uniformizar los datos, ajustamos la frecuencia de muestreo de 360 Hz de MITDB a 250 Hz, que es la frecuencia de las otras bases de datos. A partir de estos datos, seleccionamos segmentos de 5 y 10 segundos utilizando un "método de superposición", donde cada muestra abarca dos segmentos concurrentes. Luego, dividimos los datos en conjuntos de entrenamiento y validación, lo que nos permitió desarrollar y evaluar nuestro modelo de clasificación basado en una red neuronal convolucional (CNN).

TÍTULO: Un enfoque de clasificación de arritmias mediante aprendizaje profundo utilizando ECG de una sola derivación sin detección de ondas QRS

Desarrollo de modelo de redes neuronales convolucionales (CNN) para clasificar arritmias sin detectar ondas QRS



3)

El biespectro es una herramienta matemática utilizada en el análisis de señales que proporciona información sobre las relaciones de fase y amplitud entre tres componentes de frecuencia diferentes en una señal. A diferencia del espectro de potencia, que solo analiza la distribución de la energía de una señal en diferentes frecuencias, el biespectro explora las interacciones no lineales entre estas frecuencias. La aplicación del biespectro en bioingeniería es amplia y se extiende a diversas áreas [6], como:

- **Procesamiento de señales electroencefalográficas (EEG):** El biespectro se utiliza para estudiar las interacciones entre diferentes bandas de frecuencia en el EEG, lo que puede proporcionar información valiosa sobre los estados de conciencia, la epilepsia y otros trastornos neurológicos.
- **Análisis de señales electrocardiográficas (ECG):** El biespectro permite detectar cambios en la dinámica no lineal del corazón, lo que puede ser útil para el diagnóstico temprano de arritmias y otras enfermedades cardíacas.
- **Procesamiento de señales electromiográficas (EMG):** El biespectro se emplea para analizar la actividad muscular y detectar patrones de fatiga muscular, lo que tiene aplicaciones en el campo de la rehabilitación y el deporte.
- **Análisis de señales acústicas biológicas:** El biespectro se utiliza para estudiar las propiedades acústicas de señales biológicas como los sonidos emitidos por animales o los flujos sanguíneos, lo que puede proporcionar información sobre la salud y el comportamiento de los organismos.
- **Análisis de imágenes médicas:** Aunque menos común, el biespectro también se ha aplicado al análisis de imágenes médicas para extraer información sobre la textura y la estructura de los tejidos.

Ventajas

- **Sensibilidad a no linealidades:** El biespectro es una herramienta poderosa para detectar y caracterizar no linealidades en las señales, lo que es fundamental en muchos sistemas biológicos.
- **Información complementaria:** El biespectro proporciona información complementaria al espectro de potencia, lo que permite una comprensión más completa de la dinámica de la señal.
- **Robustez al ruido:** En algunos casos, el biespectro puede ser más robusto al ruido que el espectro de potencia.

Desventajas

- **Complejidad computacional:** El cálculo del biespectro puede ser computacionalmente costoso, especialmente para señales de larga duración.
- **Interpretación:** La interpretación de los resultados del biespectro puede ser compleja y requerir un conocimiento profundo de los procesos físicos que generan la señal.
- **Sensibilidad a los artefactos:** El biespectro puede ser sensible a los artefactos presentes en la señal, lo que puede complicar la interpretación de los resultados.

Bicoherencia: Es una medida normalizada del biespectro, que indica la coherencia de las interacciones de tercer orden. Valores cercanos a 1 indican una fuerte interacción no lineal.

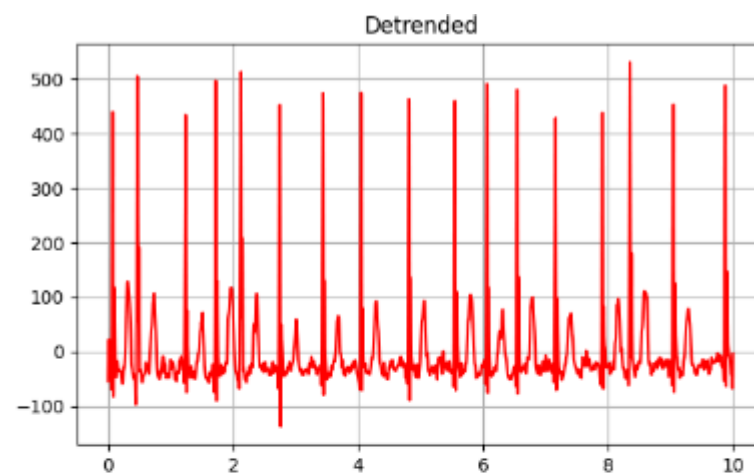

- Padding: Se asegura que la longitud de la señal sea un múltiplo de **N** para facilitar el cálculo de la FFT.
- Segmentación: La señal se divide en segmentos de longitud **N**.
- Cálculo de la FFT: Se calcula la Transformada Rápida de Fourier (FFT) de cada segmento.
- Cálculo del biespectro: Se calcula el biespectro para cada segmento y se acumula.
- Cálculo de la bicoherencia: Se calcula la bicoherencia normalizada a partir del biespectro acumulado.

bispectrum_bicoherence: Se utiliza para analizar las no lineales en una señal y detectar interacciones de tercer orden entre diferentes frecuencias.


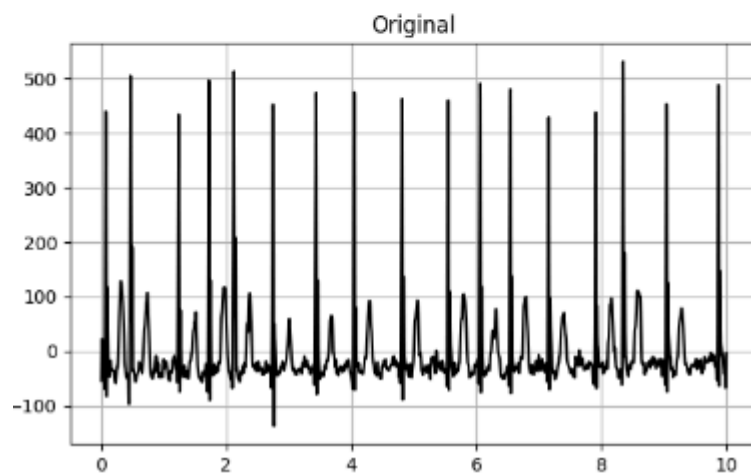
Grafica: Se utiliza para visualizar y comparar dos señales.

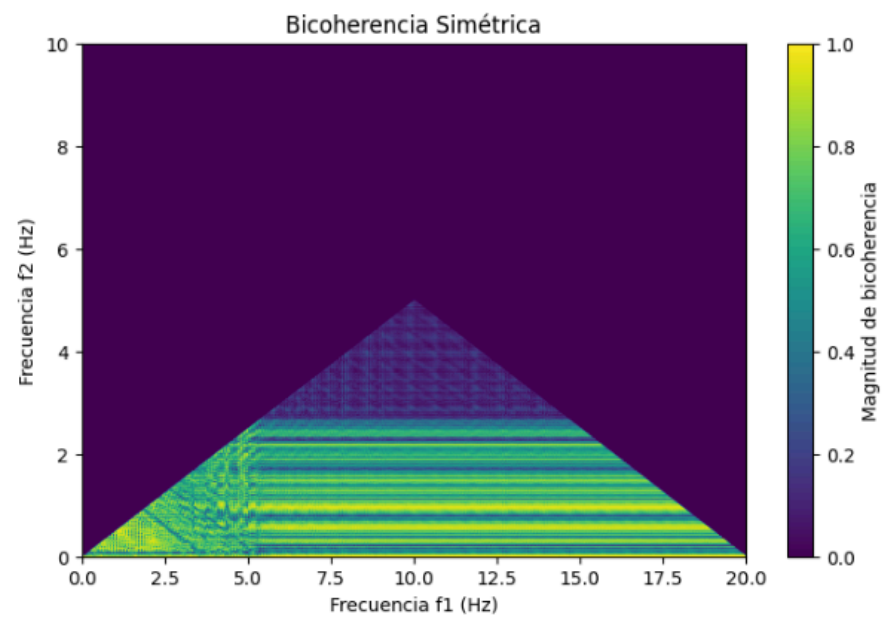
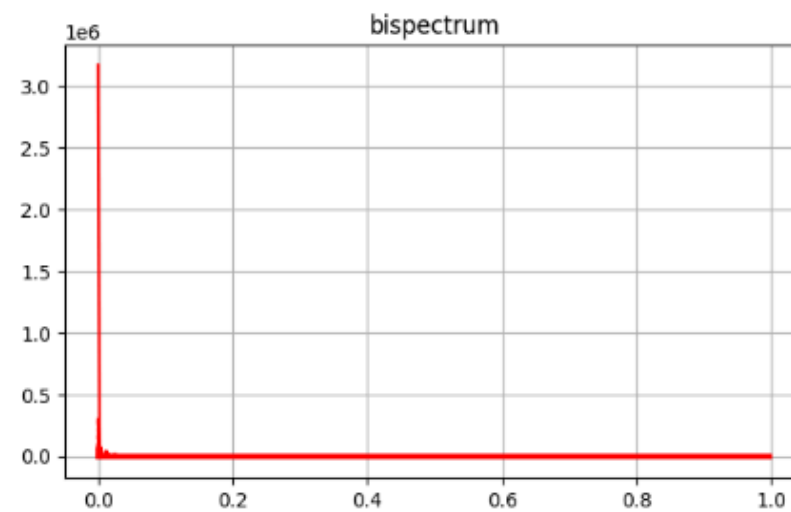

detrend_n_deviation: Se utiliza para eliminar la tendencia lineal de una señal y calcular su variabilidad.

compress: Se utiliza para normalizar los valores de una señal a un rango específico. Obtener todas las señales en un rango uniforme y se ejecuta con la resta de cada punto menos el mínimo sobre la resta del valor máximo y el mínimo de la serie temporal del ECG. Comprime la señal dejando su comportamiento original.[1]

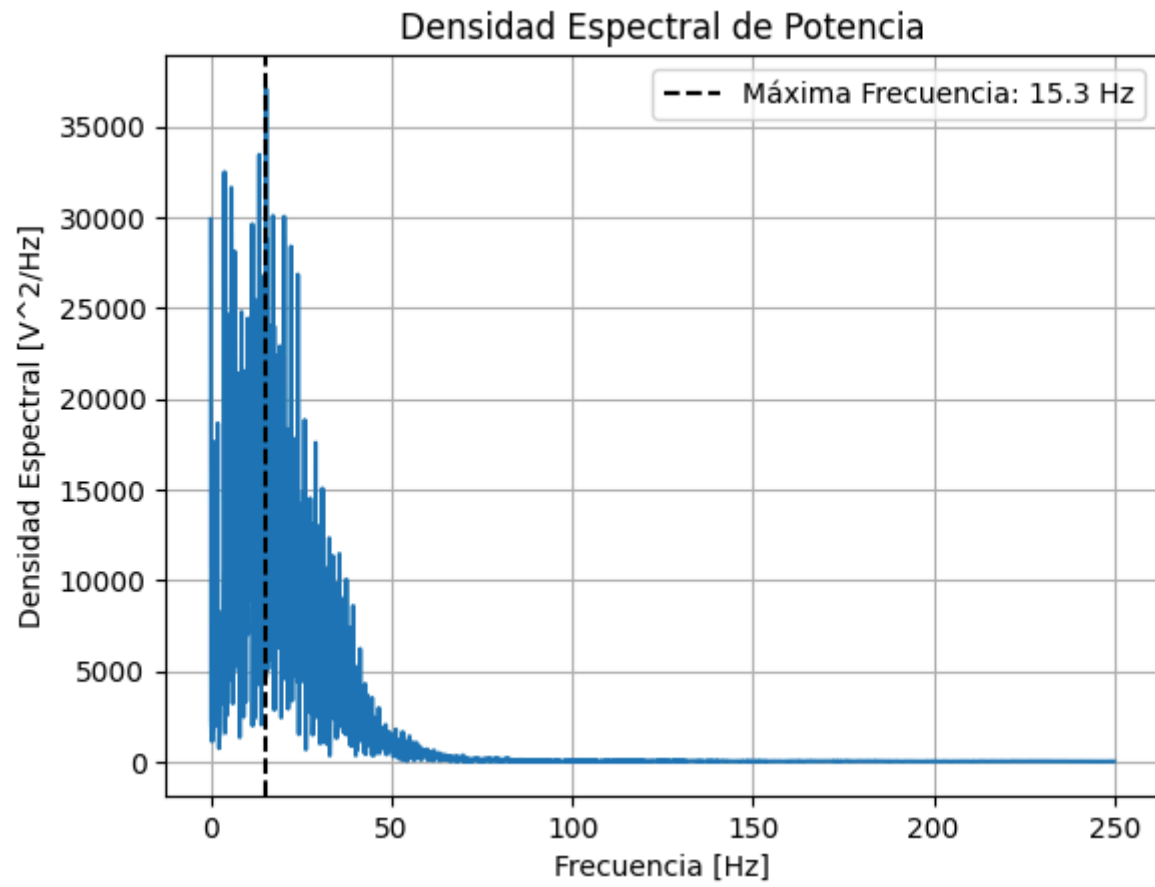


Aplicando compress





4)



5)

Las frecuencias que son significativas para bicoherencia (cuales tienen un valor superior a

$$\sqrt{\frac{9.2}{2 \cdot N}}$$

quedan registradas en el dataframe presentado más adelante

6)

	Registro	Estado	fMP	sFSB
0	MUSE_20180113_171327_27000	AFIB	9.765625	2000
1	MUSE_20180114_075026_69000	AFIB	3.906250	2000
2	MUSE_20180112_073319_29000	SB	5.859375	1987
3	MUSE_20180112_120347_79000	SB	3.906250	1998

7)

EVALUAR NORMALIDAD

Hipótesis nula (Ho): Los datos recolectados del ECG no distribuyen normal

Hipótesis alternativa (H1): Los datos distribuyen de manera normal

EVALUAR HOMOCEDASTICIDAD

Hipótesis nula (Ho): Los varianza de los datos recolectados del ECG no son significativamente diferentes

Hipótesis alternativa (H1): La varianza de los datos son significativamente diferentes

Se aplica **PRUEBAS NO PARAMÉTRICAS** debido a que incumple uno de los supuestos, el de normalidad, ya que al aplicar el test de normalidad acepta la hipótesis nula

Hipótesis nula (Ho): No hay diferencia entre la frecuencia significativa en bicoherencia entre pacientes con bradicardia sinusal (SB) y fibrilación auricular (AFIB)

Hipótesis alternativa (H1): Si hay diferencia de la frecuencia significativa en bicoherencia entre pacientes con bradicardia sinusal (SB) y fibrilación auricular (AFIB)

8)

ANÁLISIS

Cómo los datos no distribuyen de manera normal ni cumple supuesto de homocedasticidad, se aplica la prueba Mann-WHitney, obteniendo cómo resultado que se rechaza la hipótesis nula de que no hay diferencias entre las dos poblaciones de estudio, esto significa que hay diferencia entre las medidas de bicoherencia entre los pacientes con bradicardia sinusal y fibrilación auricular, debido a que estas dos enfermedades generan potencia en otras y más frecuencias diferentes a las que normalmente el corazón funciona (1-2 Hz), es decir tienen una potencia que sobrepasa el 80% en otras frecuencias, permitiendo concluir que estas dos arritmias presenta un aumento en la potencia del ECG en frecuencias determinadas que pueden servir como diagnóstico para detectar estas arritmias a tiempo. En pocas palabras estas dos arritmias tienen diferencias importantes en la interacción de frecuencias en las señales cardíacas

Bibliografía:

[1] Rivero Pouymiró, I., Valdés Córdova, E., & Valdés Pérez, F. E. (2017). Nuevo método para obtener la frecuencia cardíaca instantánea mediante el análisis espectro temporal del seismocardiograma. *Revista Cubana de Ciencias Informáticas*, 11(1), 122-135.

[2] Leber, E. L., & Campos, R. J. (2004). Detección y análisis latido a latido de potenciales tardíos ventriculares en señales ECG mediante mapas espectro-temporales. In *XXV Jornadas de Automática: Ciudad Real, 8, 9, y 10 de septiembre de 2004* (p. 23). JA Somolinos.

[3]Gadaleta, M., Harrington, P., Barnhill, E. *et al.* Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias. *npj Digit. Med.* 6, 229 (2023). <https://doi.org/10.1038/s41746-023-00966-w>

[4] Zheng, J., Chu, H., Struppa, D. *et al.* Optimal Multi-Stage Arrhythmia Classification Approach. *Sci Rep* 10, 2898 (2020). <https://doi.org/10.1038/s41598-020-59821-7>

[5] Liong-Rung Liu, Ming-Yuan Huang, Shu-Tien Huang, Lu-Chih Kung, Chao-hsiung Lee, Wen-Teng Yao, Ming-Feng Tsai, Cheng-Hung Hsu, Yu-Chang Chu, Fei-Hung Hung, Hung-Wen Chiu, An Arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection, *Heliyon*, Volume 10, Issue 5, 2024, e27200, ISSN 2405-8440, <https://doi.org/10.1016/j.heliyon.2024.e27200>.

[6] Mariño, W. A. (2016). BIESPECTRO. www.academia.edu. <https://www.academia.edu/28141592/BIESPECTRO>